LAPORAN TUGAS EKSPLORASI MANDIRI

ANALISIS PERBANDINGAN KINERJA PANDAS DAN PYSPARK DALAM PEMROSESAN DATA TABULAR PADA LINGKUNGAN SINGLE-NODE

Mata Kuliah: Mahadata / Big Data (IF25-40402)

Nama: Firman H Gultom

NIM: 123140171



Program Studi Teknik Informatika

Institut Teknologi Sumatera

2026

A. Ringkasan Jurnal

Artikel yang digunakan sebagai referensi dalam eksperimen ini ditulis oleh Y. Mekouar, M. Lahmer, dan M. Karim dengan judul "Optimizing Data Pipelines for Green AI: A Comparative Analysis of Pandas, Polars, and PySpark for CO_2 Emission Prediction" [1]. Artikel ini diterbitkan dalam jurnal Computers, volume 14, nomor 8, artikel 319, pada tahun 2025, dengan DOI 10.3390/computers14080319.

Pengolahan data merupakan bagian penting dalam analisis data, terutama ketika jumlah data yang diproses semakin besar. Pemilihan pustaka yang digunakan dapat memengaruhi waktu yang dibutuhkan untuk memproses data serta penggunaan sumber daya komputer. Dalam artikel tersebut, penulis membahas perbandingan Pandas, Polars, dan PySpark untuk pengolahan data pada pipeline prediksi emisi CO_2 [1].

Berdasarkan topik tersebut, eksperimen ini dilakukan untuk membandingkan waktu eksekusi Pandas dan PySpark dalam memproses dataset dengan jumlah baris yang berbeda. Pengujian dilakukan pada satu komputer dengan operasi pengolahan data yang sama agar hasil dari kedua pustaka dapat dibandingkan secara adil. Eksperimen ini berfokus pada pengujian kinerja pemrosesan data dan tidak mereplikasi seluruh tahapan penelitian dalam artikel acuan.

Topik ini dipilih karena berkaitan dengan materi Mahadata, khususnya penggunaan teknologi untuk mengolah data dalam jumlah besar. Pandas dan PySpark digunakan karena keduanya memiliki pendekatan pemrosesan data yang berbeda dan dapat diuji dalam lingkungan lokal. Dataset sintetis digunakan agar jumlah data dapat ditentukan sesuai kebutuhan pengujian serta memungkinkan eksperimen diulang dengan kondisi yang sama.

Dalam menyusun laporan, informasi mengenai metode dan hasil penelitian dari artikel acuan perlu disesuaikan dengan isi artikel aslinya. Sementara itu, hasil pengujian Pandas dan PySpark yang dibahas pada bagian selanjutnya didasarkan pada eksperimen yang dilakukan secara mandiri.

B. Tahapan Implementasi atau Eksperimen

1. Rancangan Eksperimen

   Eksperimen ini menggunakan dataset sintetis dalam format CSV yang berisi empat kolom, yaitu id, kategori, nilai, dan kuantitas. Dataset dibuat secara otomatis dengan pola data yang tetap agar pengujian dapat diulang menggunakan data yang sama. Jumlah data yang digunakan terdiri dari tiga variasi, yaitu 50.000, 250.000, dan 1.000.000 baris. Variasi ini digunakan untuk mengetahui perubahan waktu pemrosesan ketika jumlah data yang diolah semakin besar.

   Pengujian dilakukan menggunakan Pandas dan PySpark dengan tahapan pengolahan yang sama. Proses dimulai dengan membaca file CSV, menyaring baris yang memiliki nilai minimal 50, menghitung kolom nilai_total dari perkalian nilai dengan kuantitas, kemudian menjumlahkan nilai tersebut berdasarkan kategori. Setiap pengujian dilakukan sebanyak tiga kali untuk masing-masing ukuran dataset dan pustaka. Waktu eksekusi yang diperoleh kemudian digunakan untuk menghitung nilai rata-rata, minimum, dan maksimum. Selain mengukur waktu pemrosesan, program juga membandingkan hasil agregasi dari kedua pustaka untuk memastikan bahwa operasi yang dilakukan menghasilkan keluaran yang setara.

2. Lingkungan dan Perangkat Lunak

   Eksperimen dijalankan pada laptop dengan sistem operasi Windows. Python digunakan untuk menjalankan program, Pandas digunakan untuk pemrosesan data tabular, sedangkan PySpark digunakan untuk menjalankan operasi data menggunakan Apache Spark. Penerapan fungsi dari kedua pustaka mengacu pada dokumentasi resminya [2], [3].

PySpark dijalankan dalam mode lokal menggunakan konfigurasi local[*], sehingga seluruh proses berlangsung pada satu komputer dengan memanfaatkan inti prosesor yang tersedia. Perangkat lunak yang digunakan dalam pengujian ini meliputi Python 3.13.3, Pandas 2.2.3, PySpark 3.5.6, dan Java JDK 17. Pengujian dilakukan menggunakan konfigurasi tersebut agar waktu pemrosesan dari kedua pustaka dapat dibandingkan pada lingkungan yang sama. Untuk melengkapi dokumentasi eksperimen, spesifikasi perangkat keras, seperti jenis prosesor dan kapasitas RAM, perlu dicatat berdasarkan laptop yang digunakan.

3. Prosedur
    - Menyiapkan lingkungan virtual Python dan memasang dependensi.
    - Membuat dataset sintetis untuk setiap ukuran.
    - Menjalankan satu kali warm-up agar inisialisasi awal Spark tidak masuk ke pengukuran utama.
    - Mengukur waktu pipeline Pandas dan PySpark sebanyak tiga kali.
    - Memvalidasi kesetaraan hasil agregasi.
    - Menyimpan hasil ke CSV dan membuat grafik waktu rata-rata.

4. Batas Pengukuran

    Pengukuran waktu eksekusi mencakup proses membaca file CSV, penyaringan data, transformasi, agregasi, hingga pengambilan hasil ke driver. Waktu yang dibutuhkan untuk membuat SparkSession dan proses warm-up tidak dimasukkan dalam pengukuran. Pengujian dilakukan pada satu laptop sehingga hasilnya hanya menggambarkan kinerja Pandas dan PySpark pada lingkungan tersebut. Oleh karena itu, hasil pengujian belum dapat digunakan untuk mewakili kinerja Apache Spark pada lingkungan klaster dengan banyak komputer.

C. Hasil Pengujian dan Analisis

Pengujian dilakukan untuk membandingkan waktu eksekusi Pandas dan PySpark pada dataset berukuran 50.000, 250.000, dan 1.000.000 baris. Pengukuran mencakup waktu rata-rata, waktu minimum, dan waktu maksimum dari tiga kali pengulangan untuk setiap ukuran dataset. Hasil pengujian dicatat dalam tabel berikut.

Jumlah baris	Pustaka	Rata-rata (detik)	Min (detik)	Maks (detik)	Hasil setara
50.000	Pandas	0.023512	0.022023	0.025817	True
50.000	PySpark	0.816591	0.649792	1.097979	True
250.000	Pandas	0.107925	0.091712	0.136683	True
250.000	PySpark	1.159106	1.044633	1.369058	True
1.000.000	Pandas	0.320659	0.295461	0.333408	True
1.000.000	PySpark	1.366913	1.316632	1.450547	True

Berdasarkan hasil pengujian, Pandas memiliki waktu eksekusi rata-rata yang lebih rendah dibandingkan PySpark pada ketiga ukuran dataset. Pada dataset 50.000 baris, Pandas membutuhkan waktu rata-rata 0,023512 detik, sedangkan PySpark membutuhkan 0,816591 detik. Pada dataset 250.000 baris, waktu rata-rata Pandas meningkat menjadi 0,107925 detik dan PySpark menjadi 1,159106 detik. Sementara itu, pada dataset 1.000.000 baris, Pandas mencatat waktu rata-rata 0,320659 detik, sedangkan PySpark membutuhkan 1,366913 detik.

Perbedaan waktu tersebut menunjukkan bahwa PySpark membutuhkan waktu lebih lama dalam skenario pengujian ini. Salah satu faktor yang mungkin memengaruhi hasil adalah adanya overhead dalam pemrosesan menggunakan Spark, terutama ketika dijalankan pada satu komputer untuk operasi data yang relatif sederhana. Namun, hasil ini hanya menggambarkan pengujian pada lingkungan lokal dan tidak dapat langsung digunakan untuk menyimpulkan kinerja PySpark pada sistem terdistribusi.

Selain waktu eksekusi, program juga memeriksa kesetaraan hasil agregasi kedua pustaka. Berdasarkan hasil yang ditampilkan, seluruh ukuran dataset menghasilkan status True, yang menunjukkan bahwa keluaran Pandas dan PySpark dinyatakan setara oleh program. Dengan demikian, perbandingan waktu dilakukan terhadap hasil pengolahan yang telah melewati pemeriksaan kesetaraan tersebut.

Secara keseluruhan, Pandas lebih cepat dalam eksperimen ini, sedangkan PySpark membutuhkan waktu eksekusi yang lebih besar. Hasil tersebut perlu dipahami dengan mempertimbangkan ukuran dataset, jenis operasi, serta spesifikasi perangkat yang digunakan. Pengujian lanjutan dengan dataset yang lebih besar dan lingkungan komputasi yang berbeda dapat memberikan gambaran yang lebih lengkap mengenai perbedaan kinerja kedua pustaka.

D. Kendala dan Refleksi

Selama proses persiapan dan pelaksanaan eksperimen, terdapat beberapa kendala yang perlu diatasi, terutama pada konfigurasi lingkungan dan penyesuaian kode program. Rincian kendala, langkah penyelesaian, dan statusnya disajikan pada tabel berikut.

Kendala yang terjadi	Langkah penyelesaian	Status
Java belum terdeteksi oleh sistem sehingga PySpark tidak dapat dijalankan.	Memasang JDK 17 dan menyesuaikan variabel lingkungan JAVA_HOME serta PATH agar Java dapat dikenali melalui terminal.	Berhasil
Hasil agregasi Pandas dan PySpark sempat dinyatakan berbeda pada dataset 250.000 baris.	Memperbaiki proses validasi dengan menggunakan toleransi perbandingan angka desimal serta memeriksa kesetaraan kategori dan nilai agregasi.	Berhasil; ketiga ukuran dataset kemudian menunjukkan hasil setara.
Terjadi kesalahan pada bagian penyimpanan hasil benchmark karena data pada variabel records kosong	Memeriksa kembali struktur kode dan memperbaiki indentasi pada bagian records.append() agar hasil pengujian dapat disimpan untuk setiap pustaka.	Perlu diverifikasi setelah program dijalankan ulang.

Eksperimen ini memberikan gambaran mengenai perbedaan waktu pemrosesan Pandas dan PySpark ketika dijalankan pada satu komputer. Namun, pengujian lokal belum dapat menggambarkan keunggulan pemrosesan terdistribusi pada banyak komputer. Selain itu, penggunaan dataset sintetis membuat karakteristik data yang diuji masih terbatas dibandingkan data yang berasal dari kasus nyata.

Untuk pengembangan selanjutnya, pengujian dapat dilakukan menggunakan dataset publik dengan karakteristik yang lebih beragam. Jumlah pengulangan juga dapat ditambah agar hasil pengukuran lebih stabil. Pencatatan penggunaan memori dan spesifikasi perangkat keras perlu dilakukan untuk membantu

menjelaskan faktor-faktor yang memengaruhi waktu eksekusi. Dengan demikian, analisis kinerja kedua pustaka dapat dilakukan secara lebih menyeluruh.

E. Tautan Kode

Repository GitHub: https://github.com/Firmanhg/123140171_Tugas_Big_Data

Repository ini bersifat publik (*public*) dan memuat kode program benchmark.py, daftar pustaka Python pada requirements.txt, serta dokumentasi penggunaan pada README.md. Repository juga mencakup hasil eksperimen berupa file CSV dan grafik perbandingan waktu eksekusi Pandas dan PySpark.

Daftar Pustaka

[1] Y. Mekouar, M. Lahmer, and M. Karim, "Optimizing data pipelines for Green AI: A comparative analysis of Pandas, Polars, and PySpark for CO_2 emission prediction," Computers, vol. 14, no. 8, Art. no. 319, 2025, doi: 10.3390/computers14080319.

[2] Apache Spark, "PySpark documentation," Apache Spark 3.5.6 Documentation. [Online]. Available: https://spark.apache.org/docs/3.5.6/api/python/. [Accessed: Oct. 13, 2026].

[3] The pandas development team, "pandas documentation." [Online]. Available: https://pandas.pydata.org/docs/. [Accessed: Oct. 13, 2026].

Pernyataan penggunaan AI: AI digunakan untuk membantu perencanaan eksperimen, penyusunan draf laporan, dan pemahaman kode program. Mahasiswa tetap bertanggung jawab untuk memverifikasi sumber referensi, menjalankan program, menganalisis hasil eksperimen, serta memastikan keakuratan isi laporan.